Tytuł projektu: Implementacja sieci neuronowej DLSTM do predykcji żywotności RUL na podstawie artykuły naukowego [1] oraz trening na zbiorze danych dla silników lotniczych NASA CMAPSS

Zespół: Marcin Zwierzchowski, Jakub Makowski

[1] Wu J., Hu K., Cheng Y. - Data driven remaining useful life prediction via multiple sensor signals and deep long short-term memory neural network

Problem

W ostatnich latach jednym z intensywniej rozwijających się zastosowań sieci neuronowych jest przewidywanie RUL (remaining useful life) różnego rodzaju urządzeń mechanicznych i elektronicznych. RUL (remaining useful life) jest wartością przybliżającą czas po upłynięciu którego dany komponent lub zespół będzie wymagać serwisu bądź wymiany. Szacowanie RUL na podstawie zbieranych przebiegów czasowych odpowiednich parametrów urządzenia (np. dane z różnego rodzaju czujników lub parametry pracy) pozwala na skuteczne zapobieganie awariom, zaoszczędzenie czasu na przeglądach oraz planowanie przyszłych serwisów. Celem naszego projektu jest implementacja jak najlepszej (z uwzględnieniem ograniczeń czasowych i umiejętnościowych) sieci do predykcji RUL na przykładzie syntetycznego “datasetu” NASA CMAPSS, zawierającego przebiegi czasowe parametrów turbowentylatorowych silników lotniczych.

Wprowadzenie

Metody prognozowania RUL można podzielić na trzy kategorie:

- Metody oparte na modelach mają na celu określenie procesu degradacji maszyny poprzez stworzenie modeli matematycznych lub fizycznych (np. model procesu Markowa / Winnera / mieszanki Gaussa). Ich minusem jest to, że opierają się na modelach, które są trudne do wyznaczenia ze względu na złożone środowisko.
- Metody oparte na danych ustalają związek między uzyskanymi danymi, a RUL poprzez eksplorację i wykorzystanie danych historycznych. W ostatnich latach zaproponowano szereg skutecznych algorytmów opartych na danych, które osiągnęły dobre wyniki, w tym głównie: sieci neuronowe (m.in LSTM, CNN), SVM, XGBoost, Random Forest itd. Mniej popularną podgrupą metod opartych na danych są też metody z użyciem wskaźnika zdrowia (eng. HI – Health Index). Są to funkcje wyliczane z wartości sensorów lub cech z nich wyekstrahowanych. Są często wyprowadzane z surowych danych sensorowych poprzez przetwarzanie sygnałów. Zazwyczaj ich konstruowanie wymaga specjalistycznej wiedzy eksperckiej i to jest właśnie ich główna wada. Co więcej, dokładność przewidywania RUL jest poważnie zależna od jakości skonstruowanych HI. Zaletą głębokich sieci neuronowych jest to, że same automatycznie ekstrahują istotne cechy z surowych danych wejściowych, eliminując potrzebę ręcznego tworzenia wskaźników HI.
- Trzeci grupa to metody hybrydowe

Analiza literatury – wnioski

- Sieci RNN [8] - Struktura sprzężenia zwrotnego, z natury przystosowane do przetwarzania danych sekwencyjnych. Nie dają odpowiednich rezultatów przez brak pamięci długotrwałej - nie wychwytują zależności długoterminowych (zanikający gradient).
- CNN [2][3][5] – Wychwytywanie zależności poprzez przesuwanie kernela po przebiegu czasowym, często stosowane przy analizie łożysk (analiza dźwięku, a więc wychwytywanie zmian w okresowym sygnale). W [12] stosowane wiele kerneli o różnych rozmiarach (zaciągniete z architektury sieci Inception)
- LSTM [1][4][6][9] – Są typem RNN i rozwiązują ich problem z zanikającym gradientem (krótka pamięć). Najpopularniejsze rozwiązanie, dobre do analizy długich przebiegów czasowych dzięki bramkom input, output i forget. Duża nieliniowość - potencjalna trudność w optymalizacji. Dużo opracowań na CMAPSS ale również np. na żywotność baterii.
- Hybrydy LSTM-CNN - Starają się wykorzystywać zalety obu rozwiązań [7]
- W kontekście CMAPSS do ewaluacji sieci stosuje się Scoring Function, która w przeciwieństwie do RMSE uwzględnia asymetryczność błędu (przewidziana wartość zbyt duża lub zbyt mała) i karze bardziej za to gdy model ma tendencje do przewidywania zbyt dużych wartości RUL (wynika to z uwarunkowań kwestii bezpieczeństwa w lotnictwie)
- Z powyższych wynika, że architektura LSTM jest odpowiedniejsza do przewidywań RUL na datasecie CMAPSS. Jej wyniki score są lepsze niż sieci CNN i charakteryzują się mniejszym rozrzutem wartości w zależności od konkretnego silnika [1].
- W pracach pojawiają się różne wersje usprawnień i metod optymalizacji sieci. Jedną z częściej przewijających się jest dropout, czasem w połączeniu z metodą Monte Carlo [10], w celu szacowania niepewności.

Analiza literatury - porównanie prac i ich wyników

Nr przypisu	Rodzaj sieci	udoskonalenia	Dataset	Mean Score
2	CNN	-	CMAPSS	5859 (270-12400
3	CNN	Optymalizacja okna czasowego	CMAPSS	2130 (220-4500)
5	CNN	Separable convolutions, squeeze and excitation unit, residual connection	CMAPSS/ Łożyska	-
4	LSTM	Dropout, Monte Carlo simulation	Baterie	-
6	LSTM	Globalny mechanizm atencji	CMAPSS	1436 (220-3100)
9	LSTM	Wstępny pre-training RBM, nadzorowane dostrajanie oraz udoskonalanie z pomocą algorytmu genetycznego	CMAPSS	1672 (220-3300)
7	CNN - BiLSTM	Model hybrydowy	CMAPSS	1634 (230-3400)

Dataset

- Zbiór danych NASA CMAPSS dla silników lotniczych turbowentylatorowych
- Jest to zbiór syntetyczny wygenerowany przy użyciu specjalnego oprogramowania do symulacji degradacji. Brak szeroko dostępnych datasetów, które posiadałyby realnie zmierzone parametry (tajemnica firm + trudne do pozyskania).
- Dataset C-MAPSS oferuje cztery zestawy danych: FD001~FD004. W każdym zestawie danych znajdują się zarówno zestawy treningowe, jak i testowe.
- Dane składają się z serii cykli, a każdy zawiera 26 kolumn, które odpowiednio wskazują identyfikator silnika, indeks cyklu, trzy ustawienia operacyjne i 21 pomiarów czujników.
- FD001 ma tylko jeden model uszkodzenia, podczas gdy FD003 ma dwa nakładające się zjawiska.
- Zestawy treningowe zawierają sygnały z całego okresu eksploatacji, a dane testowe zawierają dane z wielu czujników zakończone w pewnym momencie przed awarią silnika.
- Rozmiar całego datasetu C-MAPSS to 47MB.
- Link: https://www.kaggle.com/datasets/behrad3d/nasa-cmaps

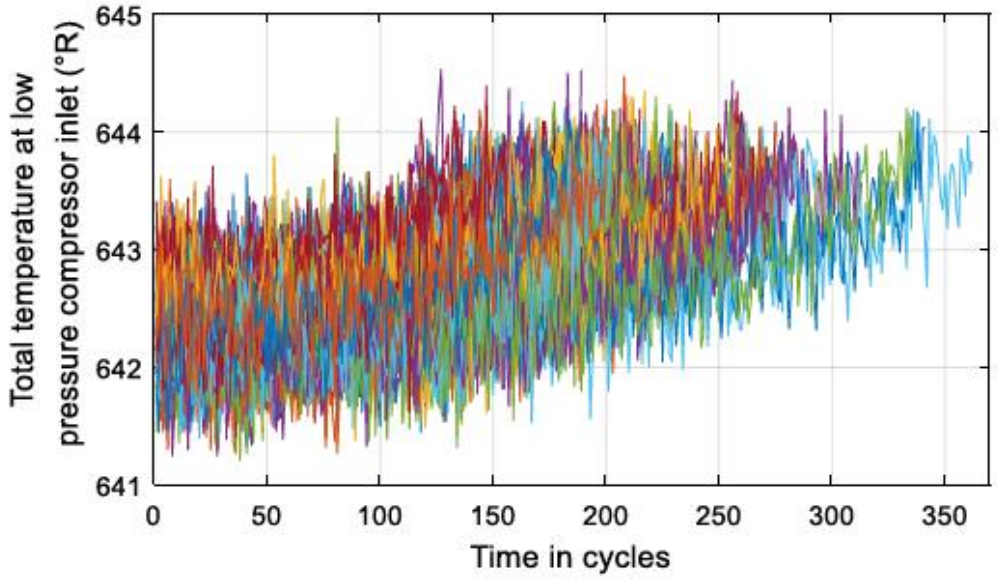


Fig. 4. Sensor 2 measurements for all engines in FD001.

Pomiary czujnika 2 dla wszystkich silników z podzbioru FD001, Src = [1]

Szczegóły artykułu [1]

- Architektura: DLSTM (Long Short-Term Memory) - umożliwia uchwycenie ukrytych długoterminowych zależności (brak problemów zanikających gradientów względem zwykłych RNNów)
- Użyte algorytmy: wykładzanie wykładnicze danych wejściowych, “grid search” do optymalizacji liczby warstw i liczby neuronów dla warstwy, optymalizacja ADAM + metoda dropout
- Hardware: IntelCore i5-4460 (3.20GHz) CPU,16 GB RAM
- Funkcja kosztu: Mean Squared Error
- Czas obliczeń: ~16h (dla 5 warstw LSTM i 100 neuronów w każdej – najlepsze rozwiązanie)
- Dataset: FD001 subdataset z CMASS (90/10 silników – split dane treningowe/testowe)
- Wejście: macierz k na t, gdzie k to liczba wybranych sensorów, a T ilość spróbkowanych danych, Wyjście: Wartość RUL
- Metryki: Score (karze późniejsze przewidywania bardziej niż wcześniejsze), RMSE*, RUL error range
- Eksperymenty / analizy: “grid search”, optymalizacja wykładzania danych wejściowych, badanie monotoniczność i korelacja danych sygnałowych w celu dokonania wyboru czujników, optymalizacja wartości dropout’u (finalnie 0.7), porównanie algorytmów minimalizacji funkcji kosztu (Adam, RMSprop, Adagrad, AdaDelta)
- Wyniki: W porównaniu z innymi metodami z tabeli* DLSTM charakteryzuje się najlepszymi wynikami.

$$Score = \begin{cases} \sum_{i=1}^{n} \exp\left(-\frac{\widehat{R}_i - R_i}{13}\right) - 1 & if\ \widehat{R}_i - R_i < 0 \\ \sum_{i=1}^{n} \exp\left(\frac{\widehat{R}_i - R_i}{10}\right) - 1 & if\ \widehat{R}_i - R_i \geq 0 \end{cases}$$

Metryka używana przy predykcji RUL, Src = [1]

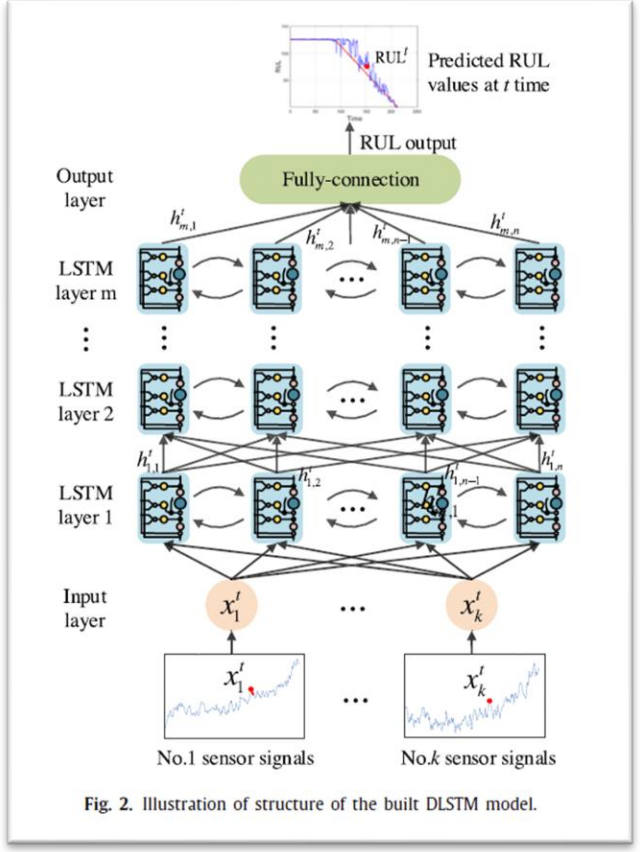


Fig. 2. Illustration of structure of the built DLSTM model.

Architektura sieci z artukułu, Src = [1]

Nasze rozwiązanie w oparciu o artykuł [1]

Celem projektu będzie zaimplementowanie od zera architektury DLSTM z artykułu [1] oraz trening sieci od zera na podzbiorze treningowym FD001 w celu porównania wyników z tymi z artykułu. Sieć zostanie zaimplementowana w najlepszej konfiguracji, która wynika z artykułu, czyli 5 warstw LSTM po 100 neuronów każda. Wykorzystanie zostany optymalizator Adam. W ramach pre-processing danych wejściowych wykorzystamy również wykładnicze wykładzanie danych wejściowych. W celu porównania zaimplementujemy metrykę “Score”. Będziemy musieli dobrać rozmiar okna czowego w danych wejściowych, ponieważ artykuł [1] nie precyzuje tego. Z analizy literatury [11] wiem, że okno o rozmiarze 50 na tym datasecie było stosowane z sukcesem. Dość długi czas treningu sieci podany w arykule najprawdopodbniej wynika z użycia tylko CPU. My planujemy skorzystać z GPU w ramach platformy Kaggle lub Google Colab.

Performance comparisons.

Methods	Score	R	RUL error range
MLP [39]	17992	37.56	N/A
SVR [39]	1381	20.96	N/A
RVR [39]	1502	23.80	N/A
DCNN [39]	1287	18.45	N/A
ELM-FC [40]	1046	N/A	[−80, 120]
SVM [41]	N/A	29.82	[−64, 69]
ESN-KF [42]	N/A	63.46	[−185, 120]
SBA [43]	791	N/A	N/A
DLSTM	655	18.33	[−47, 56]

Wyniki oraz porównanie na FD001 vs inne modele, Src = [1]

Bibliografia

- [1] Wu J., Hu K., Cheng Y. - **Data driven remaining useful life prediction via multiple sensor signals and deep long short-term memory neural network**
- [2] Li, X.; Ding, Q.; Sun, J.Q. - Remaining useful life estimation in prognostics using deep convolution neural networks.
- [3] Yang, H.; Zhao, F.; Jiang, G.; Sun, Z.; Mei, X. - A Novel Deep Learning Approach for Machinery Prognostics Based on Time Windows.
- [4] Zhang Y. - Long Short-Term Memory Recurrent Neural Network for Remaining Useful Life Prediction of Lithium-Ion Batteries
- [5] Wang B., Lei Y., Li N., Tao Y. - Deep separable convolutional network for remaining useful life prediction of machinery
- [6] de Oliveira da Costa P., Akcay A., Zhang Y., Kaymak U. - Attention and Long Short-Term Memory Network for Remaining Useful Lifetime Predictions of Turbofan Engine Degradation
- [7] Zhao C., Huang X., Li Y., Iqbal M. - A double-channel hybrid prediction model based on the CNN and a bidirectional LSTM network to avoid those drawbacks
- [8] Su C., Chen H., Wen Z. - Prediction of remaining useful life for lithium-ion battery with multiple health indicators
- [9] Listou Ellefsen, A.; Bjørlykhaug, E.; Æsøy, V.; Ushakov, S.; Zhang, H. Remaining useful life predictions for turbofan engine degradation using semi-supervised deep architecture
- [10] Gal Y., Ghahramani Z. - Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning
- [11] Arias Chao, M.; Kulkarni, C.; Goebel, K.; Fink, O. Fusing Physics-based and Deep Learning Models for Prognostics. arXiv 2020, arXiv:2003.00732.
- [12] Yang, H.; Zhao, F.; Jiang, G.; Sun, Z.; Mei, X. A Novel Deep Learning Approach for Machinery Prognostics Based on Time Windows. Appl. Sci. 2019, 9, 4813.